



UTR EIIA - Introduction à l'IA

TP - LearnRoadSign

Membres du groupe :

CARVALHO Allan
LEHAIRE Maxine

Encadrés par : E. Dokladalova & T. Desgouttes

Table des matières

Table des matières	1
Séance 1	3
Étape 1 – Import des bibliothèques	3
Étape 2 – Préparation et analyse des données	3
2.1. Préparation des données	3
Figure 1 - Distribution des images par classe	3
2.2. Analyse qualitative des données	4
Figure 2 - Exemple d'images de panneaux du dataset	4
Étape 3 – Architecture des modèles	4
Table 1 - Description des architectures	5
1. Comparaison des Modèles "Dense" (Modèles 1 & 2)	5
2. Efficacité des Modèles Convolutionnels (Modèles 3 & 4)	5
3. Stratégie de Régularisation (Modèle 4)	5
Étape 4 – Entraînement et résultats	6
Analyse de l'accuracy et de la loss	6
Table 2 - Performances comparées des 4 modèles (Séance 1)	6
Matrice de confusion	6
Figure 3 - Comparaison des matrices de confusion (Séance 1)	7
Figure 4 - Matrice de confusion du Modèle 3 (Séance 1)	8
Figure 5 - Matrice de confusion du Modèle 4 (Séance 1)	9
Analyse des métriques macro-moyennées	9
Table 3 - Métriques d'évaluation comparatives (avant prétraitement)	10
Étape 5 – Évaluation de la qualité de classification	10
Table 4 - Prédictions des 4 modèles avec le set d'images test	11
Figure 6 - Matrice de confusion des 4 modèles sur l'ensemble Test (Séance 1)	12
Séance 2	13
Étape 1– Prétraitement des images (CLAHE)	13
Figure 7 - Exemple d'images du dataset après prétraitement CLAHE	13
Table 5 - Impact du prétraitement sur les performances du Modèle 4	13
Figure 8 - bias/histogram avant prétraitement (gauche) et après (droite)	14
Figure 9 - Matrices de confusion du Modèle 4 après prétraitement CLAHE (Séance 2)	15
Table 6 - Prédiction du Modèle 4 avant et après prétraitement des images CLAHE	15
Table 7 - Performances comparées des 4 modèles après prétraitement des images CLAHE (Séance 2)	16
Étape 2 – Analyse des échecs du modèle	16
Figure 10 - Images panneaux classe 3 conditions extrêmes	16
Figure 11 - Images panneaux classe 5 conditions extrêmes	16
Table 8 - Résultats de prédiction pour les images appartenant à la classe 3 du jeu de données, en conditions extrêmes.	17
Table 9 - Résultats de prédiction pour les images appartenant à la classe 5 du jeu de données, en conditions extrêmes.	17
Étape 3 – Métriques d'évaluation (Précision, Rappel, F1-Score)	18
Matrice de confusion	18
Figure 12 - Matrice de confusion des 4 modèles sur l'ensemble Train (Séance 2)	19
Figure 13 - Matrice de confusion des 4 modèles sur l'ensemble Test (Séance 2)	20
Analyse des métriques macro-moyennées	20
Table 10 - Métriques d'évaluation comparatives (après prétraitement)	21
Conclusion	21
Annexe	22
Table 11 – Types de panneaux par classe	22

Séance 1

Étape 1 – Import des bibliothèques

Cette étape consiste à importer l'ensemble des bibliothèques Python nécessaires à la conception et à l'entraînement des réseaux de neurones, ainsi que le jeu de données utilisé pour entraîner les modèles. Les bibliothèques principales utilisées sont TensorFlow/Keras pour la définition et l'entraînement des réseaux, NumPy et Matplotlib pour le traitement des données et la visualisation, ainsi que scikit-learn pour le calcul des métriques d'évaluation.

Étape 2 – Préparation et analyse des données

Dans cette partie, on s'occupe de préparer les données qui entraîneront nos modèles.

2.1. Préparation des données

Le dataset contient 21 355 images réparties en 43 classes (cf. Annexe - Table 10 pour connaître le contenu des classes).

Après préparation les données ont la forme (21355, 30, 30, 3) ce qui signifie que chaque image a été redimensionnée en 30 × 30 pixels avec 3 canaux de couleur.

On répartit alors chaque nombre d'image dans une liste pour en fournir un graphique.

Le graphique de distribution des classes (cf. Figure 1) montre que le dataset est déséquilibré. Certaines classes possèdent beaucoup plus d'images que d'autres. Par exemple, la classe 1 ne contient que 66 images tandis que la classe 38 en contient 921.




Figure 1 - Distribution des images par classe

2.2. Analyse qualitative des données



Figure 2 - Exemple d'images de panneaux du dataset

1. Quelle est la qualité d'images ?

La qualité des images est assez mauvaise, on peut voir que les images des panneaux sont très pixelisées, certaines sont plus floues et bruitées que d'autres. De plus, selon les images, la luminosité est également assez faible, ce qui dégrade encore la lisibilité des panneaux.

2. Les panneaux ont-ils toujours la même position, la même forme ?

Les panneaux ont globalement la même position : à l'endroit, mais ils peuvent être plus ou moins proches, donc de taille plus ou moins grande et pas toujours centrés. Les panneaux n'ont pas la même forme puisqu'il y a des panneaux ronds et triangulaires par exemple.

3. Quelles conséquences pour l'apprentissage ?

La faible qualité des images rend la tâche de reconnaissance plus difficile et peut entraîner une baisse de la précision. Les variations de taille et de position des panneaux obligent le modèle à être robuste aux transformations spatiales. Le fait que les panneaux n'aient pas toujours la même forme peut parfois aider à la distinction entre les différentes classes, ou au contraire être inconvenient pour délimiter l'objet panneau.

Étape 3 – Architecture des modèles

À cette étape, nous construisons 4 modèles de réseaux de neurones artificiels :

- le modèle 1 contient deux couches Dense,
- le modèle 2 contient trois couches Dense,
- le modèle 3 contient une couche Convolutionnelle + deux couches Dense,
- le modèle 4 contient deux couches Convolutionnelles + deux couches Dense + un Dropout au milieu des couches Dense.

Modèle	Type	Couches	Paramètres	Taille (MB)
Modèle 1	Dense 2 couches	Flatten → Dense(512) → Dense(256) → Dense(43)	1 525 291	5,82
Modèle 2	Dense 3 couches	Flatten → Dense(512) → Dense(256) → Dense(128) → Dense(43)	1 552 683	5,92
Modèle 3	CNN simple	Conv2D(32) → MaxPool → Flatten → Dense(128) → Dense(64) → Dense(43)	814 891	3,11
Modèle 4	CNN + Dropout	Conv2D(32) → MaxPool → Conv2D(64) → MaxPool → Flatten → Dense(512) → Dropout(0.3) → Dense(256) → Dense(43)	< 1 000 000	< 4

Table 1 - Description des architectures

1. Comparaison des Modèles "Dense" (Modèles 1 & 2)

Les modèles 1 et 2 reposent sur des couches Dense (entièrement connectées). Pour traiter l'image, celle-ci est d'abord "aplatie" (couche *Flatten*), perdant ainsi sa structure spatiale 2D.

Avec environ 1,5 million de paramètres (cf. Table 1), ces modèles sont les plus lourds. Cela s'explique par le fait que chaque pixel de l'image d'entrée est connecté à chaque neurone de la couche suivante.

L'ajout d'une couche intermédiaire dans le modèle 2 (128 neurones) augmente la profondeur du réseau. Bien que cela puisse aider à capturer des relations plus complexes, le gain en performance reste souvent faible par rapport à l'augmentation de la taille du modèle (5,92 MB) (cf. Table 1).

2. Efficacité des Modèles Convolutionnels (Modèles 3 & 4)

Le modèle 3 introduit des couches de Convolution (Conv2D) et de Pooling. Contrairement aux couches Dense, la convolution analyse l'image par zones locales, ce qui est bien plus adapté au traitement visuel.

On observe une réduction drastique du nombre de paramètres (~815 000, soit presque 50% de moins que les modèles 1 et 2). Le modèle est donc plus léger (3,11 MB) et plus rapide à entraîner (cf. Table 1).

En utilisant des filtres, ces modèles parviennent à extraire des caractéristiques spécifiques (bords, textures) tout en réduisant la dimensionnalité grâce au *MaxPooling*.

3. Stratégie de Régularisation (Modèle 4)

Le Modèle 4 est une version plus puissante et plus robuste que le Modèle 3. Pour mieux reconnaître les 43 types de panneaux, nous avons ajouté une deuxième couche de

convolution (64 filtres) et augmenté massivement le nombre de neurones dans les couches finales (512 et 256). (cf. Table 1)

Cette plus grande capacité permet au réseau de comprendre des détails plus complexes. Pour éviter que le modèle ne se contente d'apprendre par cœur les images d'entraînement, nous avons intégré un Dropout de 30 %. Cette technique "désactive" temporairement certains neurones, forçant le reste du réseau à devenir plus efficace et autonome. Au final, cette architecture est la plus équilibrée : elle est assez large pour bien apprendre et assez régulée pour s'adapter parfaitement à de nouvelles images.

Étape 4 – Entraînement et résultats

Dans cette partie, nous procédons à l'entraînement du réseau pour chaque modèle. Nous utilisons un outil dédié au suivi des performances d'apprentissage (TensorBoard), nous permettant d'évaluer et de comparer les résultats obtenus par chacun d'eux.

Analyse de l'accuracy et de la loss

Chaque modèle a été entraîné sur 20 epochs. Les résultats obtenus sur les ensembles d'entraînement et de validation sont présentés dans le tableau suivant.

Modèle	Accuracy Train	Accuracy Val	Loss Train	Loss Val	Temps / Époque
Modèle 1	89,35 %	85,51 %	0,4001	0,6634	~57 sec
Modèle 2	85,88 %	86,65 %	0,5174	0,5496	~1,04 min
Modèle 3	99,96 %	97,99 %	0,0045	0,1299	~57 sec
Modèle 4	99,16 %	98,83 %	0,0357	0,0504	~1,05 min

Table 2 - Performances comparées des 4 modèles (Séance 1)

Les modèles Dense (1 et 2) atteignent des précisions de validation modérées (85-87 %) avec des pertes élevées, signe que l'aplatissement de l'image détruit une information spatiale essentielle à la reconnaissance des panneaux. On remarque également un écart significatif entre la perte d'entraînement et celle de validation pour le modèle 1, ce qui suggère un début de sur-apprentissage.

Les modèles convolutifs (3 et 4) surpassent largement les modèles Dense, avec des précisions de validation dépassant 98 %. Le modèle 4 se distingue par un meilleur équilibre entre train et validation (99,16 % vs 98,83 %) et une perte de validation très faible (0,0504), ce qui indique une bonne généralisation grâce au Dropout.

Matrice de confusion

Pour aller plus loin, nous pouvons générer la matrice de confusion de chacun des modèles.

Comparaison des Matrices de Confusion - Séance 1




Figure 3 - Comparaison des matrices de confusion (Séance 1)

Pour les Modèles 1 et 2, on remarque un "bruit" important autour de la diagonale principale. De nombreux points bleus clairs apparaissent hors de la diagonale, ce qui indique des confusions fréquentes entre différentes classes de panneaux. Ces architectures denses peinent à capturer les caractéristiques spatiales complexes des images, même après égalisation.

Pour les Modèles 3 et 4, la diagonale devient beaucoup plus nette et marquée. L'introduction des couches de convolution permet au modèle de mieux distinguer les formes géométriques. La réduction drastique des points hors-diagonale montre que les erreurs grossières diminuent fortement.

Zoom sur les différences entre les matrices de confusion des modèles 3 et 4

La comparaison entre ces deux matrices montre que le Modèle 4 est le plus précis. Les scores de prédictions correctes sur la diagonale sont généralement supérieurs d'un à deux

points par rapport à ceux du Modèle 3. L'ajout du Dropout a permis d'affiner les frontières de décision, éliminant certaines confusions résiduelles du Modèle 3. (cf. Figure 4 & 5)




Figure 4 - Matrice de confusion du Modèle 3 (Séance 1)




Figure 5 - Matrice de confusion du Modèle 4 (Séance 1)

Analyse des métriques macro-moyennées

Pour une évaluation rigoureuse, on peut même devancer l'Étape 3 de la Séance 2 en évaluant trois métriques complémentaires : la Précision, le Rappel (Recall) et le F1-Score. (Ces trois métriques sont détaillées dans l'[Étape 3 de la Séance 2](#).)

L'analyse comparative des performances (cf. Table 3) démontre une progression fulgurante des capacités du réseau en fonction de son architecture, l'accuracy globale bondissant de 83-85 % pour les modèles denses à plus de 99 % pour le modèle convolutif optimisé. Le Modèle 4 s'impose comme la référence absolue avec une accuracy de 99,04 % et un F1-Score macro de 98,90 %, prouvant une fiabilité et une capacité de détection quasi parfaites sur l'ensemble des 43 classes. La forte proximité entre la précision, le rappel et le F1-Score pour ce modèle atteste d'une grande robustesse face au déséquilibre du dataset, confirmant qu'il ne sacrifie pas les classes minoritaires au profit des plus fréquentes. À l'inverse, les modèles denses affichent des lacunes structurelles, notamment un rappel plus faible (78,72 % pour le modèle 2), ce qui souligne l'incapacité des réseaux entièrement connectés à préserver l'information spatiale nécessaire à une reconnaissance précise des panneaux.

Métrique	Modèle 1	Modèle 2	Modèle 3	Modèle 4
Précision (macro)	83,58 %	82,78 %	96,34 %	98,87 %
Rappel (macro)	84,10 %	78,72 %	96,06 %	98,94 %
F1-Score (macro)	82,86 %	79,45 %	96,17 %	98,90 %
Accuracy globale	85,79 %	83,12 %	96,46 %	99,04 %

Table 3 - Métriques d'évaluation comparatives (avant prétraitement)

Étape 5 – Évaluation de la qualité de classification

Afin de confronter nos modèles à des conditions réelles, nous avons procédé à une phase de test final en utilisant un échantillon d'images extraites du fichier test.zip. Ces images sont dites "inconnues" car elles n'ont été présentées aux modèles ni lors de l'entraînement, ni lors de la phase de validation.

Cette présentation permet d'identifier instantanément si le modèle a correctement identifié le panneau. Le tableau ci-dessous résume les performances obtenues sur cet échantillon de 11 images.

Image	Classe	Modèle 1	Modèle 2	Modèle 3	Modèle 4
00000.png	Classe 16	✗ Classe 7 (Conf : 3,6%)	✗ Classe 5 (Conf : 3,6%)	✓ Classe 16 (Conf : 3,8%)	✗ Classe 5 (Conf : 5,5%)
00001.png	Classe 1	✗ Classe 8 (Conf : 3,6%)	✗ Classe 5 (Conf : 3,8%)	✗ Classe 8 (Conf : 5,2%)	✗ Classe 4 (Conf : 5,2%)
00002.png	Classe 38	✓ Classe 38 (Conf : 4,2%)	✗ Classe 20 (Conf : 3,5%)	✓ Classe 38 (Conf : 4,5%)	✗ Classe 5 (Conf : 4,4%)
00003.png	Classe 33	✗ Classe 31 (Conf : 3,0%)	✗ Classe 31 (Conf : 3,2%)	✓ Classe 33 (Conf : 4,2%)	✓ Classe 33 (Conf : 4,6%)
00004.png	Classe 11	✗ Classe 20 (Conf : 3,0%)	✗ Classe 25 (Conf : 3,4%)	✗ Classe 23 (Conf : 3,9%)	✗ Classe 8 (Conf : 3,9%)
00005.png	Classe 38	✓ Classe 38 (Conf : 3,0%)	✗ Classe 20 (Conf : 3,4%)	✓ Classe 38 (Conf : 4,3%)	✗ Classe 5 (Conf : 4,1%)
00006.png	Classe 18	✗ Classe 31 (Conf : 3,1%)	✗ Classe 25 (Conf : 3,4%)	✓ Classe 18 (Conf : 4,4%)	✗ Classe 26 (Conf : 4,4%)
00007.png	Classe 12	✗ Classe 8 (Conf : 3,3%)	✗ Classe 25 (Conf : 3,4%)	✗ Classe 8 (Conf : 3,8%)	✗ Classe 8 (Conf : 4,2%)
00008.png	Classe 25	✓ Classe 25	✓ Classe 25	✓ Classe 25	✓ Classe 25

		(Conf : 3,5%)	(Conf : 3,8%)	(Conf : 5,1%)	(Conf : 5,2%)
00009.png	Classe 35	✗ Classe 3 (Conf : 3,4%)	✗ Classe 3 (Conf : 3,3%)	✗ Classe 25 (Conf : 3,9%)	✗ Classe 5 (Conf : 4,0%)
00010.png	Classe 12	✗ Classe 20 (Conf : 2,8%)	✗ Classe 25 (Conf : 3,5%)	✗ Classe 25 (Conf : 3,6%)	✗ Classe 5 (Conf : 4,2%)
Total		3/11	1/11	6/11	2/11
Confiance moyenne		3,3%	3,5%	4,2%	4,5%

Table 4 - Prédictions des 4 modèles avec le set d'images test

Malgré une excellente stabilité et une précision théorique optimale, le Modèle 4 n'obtient que 2/11 sur notre set de test (cf. Table 4). Ce score paradoxal montre que la régularisation par Dropout, bien qu'efficace contre le surapprentissage, peut rendre le réseau hésitant face à un échantillon réduit ou des images aux conditions variées après seulement 20 epochs.

On observe aussi que les indices de confiance sont extrêmement faibles pour l'ensemble des modèles, plafonnant aux alentours de 3% à 5%. Cette absence de certitude prouve que les réseaux ne parviennent pas à extraire de caractéristiques discriminantes claires sur ces images de test.

De plus, la variabilité des prédictions selon les exécutions confirme que le modèle n'a pas réellement convergé vers une décision robuste.

En effet, L'analyse des matrices de confusion de l'ensemble TEST (avant prétraitement) (cf. Figure 6) met en évidence une difficulté généralisée des modèles à classer correctement cet échantillon de 11 images. Contrairement aux matrices d'entraînement, on observe ici une absence presque totale de ligne diagonale. La majorité des carrés bleus se situent dans les zones blanches de la grille, ce qui signifie que les modèles prédisent des classes erronées pour presque toutes les images présentées.




Figure 6 - Matrice de confusion des 4 modèles sur l'ensemble Test (Séance 1)

Ce constat démontre qu'une architecture complexe ne suffit pas à compenser une donnée brute difficile. Pour transformer cette précision théorique en performance réelle, il est indispensable d'optimiser la qualité de l'information visuelle fournie (via l'égalisation d'histogramme par exemple) afin de stabiliser les prédictions.

Séance 2

L'objectif de cette séance est d'améliorer la robustesse du Modèle 4 (notre meilleure architecture) en agissant non plus sur le réseau lui-même, mais sur la qualité des données d'entrée. Nous avons émis l'hypothèse que les échecs sur les images de test étaient dus à des défauts de contraste et de luminosité.

Étape 1– Prétraitement des images (CLAHE)

Dans cette étape, un nouvel entraînement est réalisé en intégrant une étape de prétraitement des images. Celle-ci consiste à améliorer leur qualité, notamment par des techniques telles que l'égalisation de l'histogramme ou la normalisation.

Nous avons utilisé la fonction `exposure.equalize_adapthist` de la bibliothèque `scikit-image` (CLAHE : Contrast Limited Adaptive Histogram Equalization). Cette technique améliore localement le contraste d'une image en égalisant son histogramme de manière adaptative, ce qui permet de révéler des détails dans les zones sombres ou sur-exposées sans altérer la structure globale. (cf. Figure 7)




Figure 7 - Exemple d'images du dataset après prétraitement CLAHE

Le prétraitement améliore les deux indicateurs : la perte de validation passe de 0,0504 à 0,0283 (-44 %), et la précision de validation progresse de 98,83 % à 99,11 %. La convergence est plus rapide et plus régulière dès les premières epochs, signe que le modèle reçoit un signal visuel plus cohérent. (cf. Table 5)

Condition	Accuracy Train	Accuracy Val	Loss Train	Loss Val	Temps / Époque
Avant prétraitement	99,16 %	98,83 %	0,0357	0,0504	~1,05 min
Après prétraitement (CLAHE)	99,92 %	99,11 %	0,0062	0,0283	~1,05 min

Table 5 - Impact du prétraitement sur les performances du Modèle 4

L'analyse comparative des matrices de confusion (cf. Figures 5 et 9) confirme que le prétraitement des données a permis de réduire des erreurs de classification. On observe une amélioration notable sur les classes visuellement proches : par exemple, les confusions entre les classes 5 et 3 sont passées de 6 à 4 cas, tandis que les erreurs entre les classes 7 et 3 ont été totalement éliminées (passant de 3 à 0). Ces résultats démontrent que l'égalisation des images a permis de clarifier les frontières de décision du modèle, facilitant la distinction entre des panneaux aux caractéristiques morphologiques similaires.




Figure 9 - Matrices de confusion du Modèle 4 après prétraitement CLAHE (Séance 2)

Le résultat le plus marquant est le test sur les 11 images inconnues : le modèle passait de 2/11 avant prétraitement à 9/11 après. L'égalisation d'histogramme a permis de normaliser le signal visuel des images sombres, permettant au modèle de reconnaître beaucoup plus facilement les panneaux même en conditions d'éclairage difficiles. La confiance moyenne bondit également de 4,5% à 90,1%. Cela indique que le modèle ne se contente plus de "deviner" au hasard, mais qu'il identifie désormais des caractéristiques visuelles claires et discriminantes. (cf. Table 6)

Image	Classe	Modèle 4 avant prétraitement	Modèle 4 après prétraitement
00000.png	Classe 16	✗ Classe 5 (Conf : 5,5%)	✓ Classe 16 (Conf : 100,0%)
00001.png	Classe 1	✗ Classe 4 (Conf : 5,2%)	✗ Classe 5 (Conf : 73,2%)
00002.png	Classe 38	✗ Classe 5 (Conf : 4,4%)	✓ Classe 38 (Conf : 100,0%)
00003.png	Classe 33	✓ Classe 33 (Conf : 4,6%)	✓ Classe 35 (Conf : 100,0%)
00004.png	Classe 11	✗ Classe 8 (Conf : 3,9%)	✗ Classe 30 (Conf : 65,2%)
00005.png	Classe 38	✗ Classe 5 (Conf : 4,1%)	✓ Classe 38 (Conf : 100,0%)
00006.png	Classe 18	✗ Classe 26 (Conf : 4,4%)	✓ Classe 38 (Conf : 99,9%)
00007.png	Classe 12	✗ Classe 8 (Conf : 4,2%)	✓ Classe 12 (Conf : 91,4%)
00008.png	Classe 25	✓ Classe 25 (Conf : 5,2%)	✓ Classe 25 (Conf : 100,0%)
00009.png	Classe 35	✗ Classe 5 (Conf : 4,0%)	✓ Classe 35 (Conf : 100,0%)
00010.png	Classe 12	✗ Classe 5 (Conf : 4,2%)	✓ Classe 12 (Conf : 61,9%)
Total		2/11	9/11
Confiance moyenne		4,5%	90,1%

Table 6 - Prédiction du Modèle 4 avant et après prétraitement des images CLAHE

Le prétraitement bénéficie à tous les modèles. Les modèles Dense voient leur précision augmenter sensiblement (+9 % environ pour le modèle 1), mais restent limités par l'absence

de traitement spatial. Les modèles CNN progressent également, le modèle 4 restant le plus performant et le plus généralisable. (cf. Table 7)

Modèle	Accuracy Train	Accuracy Val	Loss Train	Loss Val	Temps / Époque
Modèle 1	97,95 %	94,66 %	0,1016	0,2157	~1,02 min
Modèle 2	98,48 %	94,08 %	0,0732	0,2315	~1,21 min
Modèle 3	99,94 %	97,89 %	0,0113	0,0833	~58 sec
Modèle 4	99,92 %	99,11 %	0,0062	0,0283	~1,05 min

Table 7 - Performances comparées des 4 modèles après prétraitement des images CLAHE (Séance 2)

Étape 2 – Analyse des échecs du modèle

À présent, nous voulons encore améliorer le modèle en cherchant ses failles pour les corriger. Pour deux classes de panneaux distinctes, il s'agit de trouver dans le dataset des images pour lesquelles notre meilleure architecture échoue.

Observation : L'analyse de la matrice de confusion (cf. Figure 9) révèle que le modèle confond ponctuellement le panneau "60 km/h" (Classe 3) avec le panneau "80 km/h" (Classe 5).

Afin de confirmer les faiblesses identifiées lors de l'analyse de la matrice de confusion, un jeu de données spécifique composé d'images en conditions dégradées a été constitué (cf. Figure 10 et 11).




Figure 10 - Images panneaux classe 3 conditions extrêmes



Figure 11 - Images panneaux classe 5 conditions extrêmes

Les résultats obtenus (Tables 8 et 9) valident nos hypothèses sur la fragilité du modèle face aux similitudes morphologiques.




Images	 00003_00000_00000.png	 00003_00009_00001.png	 00003_00012_00001.png	 00003_00001_00029.png
Classe prédite	Classe 5 ❌	Classe 3 ✅	Classe 3 ✅	Classe 5 ❌
Confiance	55,19%	98,57%	83,76%	34,03%

Table 8 - Résultats de prédiction pour les images appartenant à la classe 3 du jeu de données, en conditions extrêmes.

On remarque que lorsque l'image est très sombre ou floue (première et dernière image), l'indice de confiance chute (34% et 55%). Le modèle n'arrive plus à distinguer la boucle supérieure du chiffre "6".

Images	 00005_00000_00000.png	 00005_00002_00000.png	 00005_00021_00005.png	 00005_00022_00016.png
Classe prédite	Classe 5 ✅	Classe 10 ❌	Classe 5 ✅	Classe 5 ✅
Confiance	73,32%	45,97%	85,70%	71,26%

Table 9 - Résultats de prédiction pour les images appartenant à la classe 5 du jeu de données, en conditions extrêmes.

Le modèle s'en sort mieux sur cette classe avec 75% de réussite, mais présente une erreur de classification majeure. Une image est prédite comme Classe 10 (Interdiction de dépasser pour les poids lourds) avec une confiance de 45%. Dans des conditions de très faible luminosité, le modèle ne perçoit plus les chiffres au centre du panneau. Il semble alors interpréter les masses sombres floues comme les deux silhouettes de camions caractéristiques de la classe 10. Cela démontre que si le contraste est trop faible, le CNN "invente" des formes basées sur des motifs qu'il a mémorisés durant l'entraînement.

Piste de solution :

- Nos observations indiquent que le modèle peine à distinguer des détails morphologiques fins (différence entre "6" et "8") dans des conditions dégradées. Passer d'une résolution de 30x30 pixels à une résolution supérieure (ex: 48x48 ou 64x64) pourrait fournir une densité de pixels plus importante pour que les filtres de

convolution puissent capturer plus de détails sur les chiffres centraux, même en présence de flou.

- Si les erreurs persistent, il est possible que certaines classes soient sous-représentées dans des conditions difficiles au sein du dataset. Augmenter la proportion d'images "difficiles" pour les classes de limitation de vitesse lors de l'entraînement pourrait apprendre au modèle à être plus "prudent" et à ne pas déduire par défaut une classe (comme la classe 10) dès que le centre d'un panneau est illisible.

Étape 3 – Métriques d'évaluation (Précision, Rappel, F1-Score)

Pour valider la robustesse de nos modèles après prétraitement, nous avons analysé leurs performances à travers les matrices de confusion et des métriques statistiques avancées.

Matrice de confusion

L'affichage des matrices de confusion sur l'ensemble d'entraînement (TRAIN) et de test (TEST) permet de visualiser la répartition des erreurs sur les 43 classes.

Sur l'ensemble TRAIN : Les quatre modèles affichent une diagonale principale très marquée. Pour les Modèles 1 et 2, on remarque encore un peu de "bruit" résiduel. Pour les Modèle 3 et 4, cette diagonale est quasi parfaite, ce qui confirme que le réseau a réussi à apprendre les caractéristiques discriminantes de chaque classe durant les 20 epochs d'entraînement. (cf. Figure 12)




Figure 12 - Matrice de confusion des 4 modèles sur l'ensemble Train (Séance 2)

Sur l'ensemble TEST : on remarque des résultats nettement meilleurs qu'avant le prétraitement des images (cf. Figure 6 et 13). On observe que pour le Modèle 4, les prédictions (carrés bleus) se concentrent sur la diagonale, validant le score de 10/11 obtenu à cette exécution-ci. À l'inverse, les modèles Dense montrent quelques points éparpillés hors-diagonale, illustrant leurs confusions persistantes malgré l'amélioration des images. Le Modèle 3 est également moins performant sur ce set de Test par rapport à l'ensemble Train, signe que le modèle commence à mémoriser les données et à faire du surapprentissage.

Matrices de Confusion - Ensemble TEST




Figure 13 - Matrice de confusion des 4 modèles sur l'ensemble Test (Séance 2)

Analyse des métriques macro-moyennées

Pour une évaluation rigoureuse en classification multi-classes, trois métriques complémentaires ont été calculées en mode macro (moyenne équilibrée sur les 43 classes) via scikit-learn, en plus de l'accuracy globale.

Précision (Precision) : La précision mesure la fiabilité du modèle lorsqu'il affirme avoir trouvé une classe spécifique. (Exemple : « Quand le modèle prédit un panneau "Stop", quelle est la probabilité que ce soit réellement un panneau "Stop" ? »)

Rappel (Recall) : Le rappel mesure la capacité du modèle à identifier toutes les instances réelles d'une classe sans en oublier. (Exemple : « Sur 100 panneaux "Stop" présents sur la route, combien le modèle a-t-il réussi à en détecter ? »)

F1-Score : Le F1-Score est la moyenne harmonique entre la précision et le rappel. Il est essentiel pour valider la performance sur les 43 classes, car il pénalise sévèrement les modèles qui sacrifieraient les classes rares pour obtenir une bonne accuracy globale.

Métrique	Modèle 1	Modèle 2	Modèle 3	Modèle 4
Précision (macro)	94,97 %	94,47 %	97,92 %	99,12 %
Rappel (macro)	94,66 %	94,08 %	97,89 %	99,11 %
F1-Score (macro)	94,68 %	94,09 %	97,89 %	99,11 %
Accuracy globale	94,66 %	94,08 %	97,89 %	99,11 %

Table 10 - Métriques d'évaluation comparatives (après prétraitement)

Les résultats (cf. Table 10) confirment la supériorité du modèle 4 sur l'ensemble des métriques. La forte proximité entre la précision, le rappel et le F1-Score pour tous les modèles indique que les erreurs ne sont pas concentrées sur quelques classes précises, mais uniformes sur l'ensemble des classes.

Le F1-Score macro est particulièrement révélateur pour ce dataset déséquilibré : un modèle qui ignorerait les classes minoritaires obtiendrait une bonne accuracy mais un F1-Score bien plus faible. Ici, le modèle 4 obtient 99,11 % de F1-Score, ce qui atteste d'une performance équilibrée sur l'ensemble des 43 classes.

Les modèles Dense affichent un écart légèrement plus grand entre précision (94,97 % / 94,47 %) et rappel, suggérant qu'ils sur-prédisent certaines classes fréquentes au détriment des classes rares. Ce phénomène est atténué dans les CNN grâce à leur meilleure capacité d'extraction de caractéristiques.

Conclusion

Ce TP a illustré la progression de performances que l'on peut obtenir en faisant évoluer l'architecture d'un réseau de neurones, puis en améliorant la qualité des données d'entrée.

Les réseaux entièrement connectés (Dense) atteignent rapidement leurs limites pour la classification d'images, car l'aplatissement détruit l'information spatiale. Les réseaux convolutifs (CNN) résolvent ce problème en étant capables d'extraire hiérarchiquement des caractéristiques visuelles.

L'ajout d'un prétraitement par égalisation adaptative de l'histogramme (CLAHE) a transformé le modèle 4, initialement fragile face aux images sombres, en un système de reconnaissance robuste (9/11) sur les images test en conditions difficiles.

Cette expérience confirme qu'en Deep Learning, la qualité et le prétraitement des données sont aussi déterminants que le choix de l'architecture.

Annexe

Table 11 – Types de panneaux par classe

Classe	Signification du panneau	Type
0	Limitation de vitesse (20 km/h)	Réglementation
1	Limitation de vitesse (30 km/h)	Réglementation
2	Limitation de vitesse (50 km/h)	Réglementation
3	Limitation de vitesse (60 km/h)	Réglementation
4	Limitation de vitesse (70 km/h)	Réglementation
5	Limitation de vitesse (80 km/h)	Réglementation
6	Fin de limitation (80 km/h)	Fin d'interdiction
7	Limitation de vitesse (100 km/h)	Réglementation
8	Limitation de vitesse (120 km/h)	Réglementation
9	Interdiction de dépasser	Réglementation
10	Interdiction de dépasser (poids lourds)	Réglementation
11	Priorité à la prochaine intersection	Danger
12	Route prioritaire	Priorité
13	Cédez le passage	Priorité
14	Stop	Priorité
15	Circulation interdite	Réglementation
16	Interdiction aux véhicules de marchandises	Réglementation
17	Sens interdit	Réglementation
18	Danger général	Danger
19	Virage à gauche dangereux	Danger
20	Virage à droite dangereux	Danger
21	Succession de virages	Danger

22	Cassis ou dos-d'âne	Danger
23	Chaussée glissante	Danger
24	Chaussée rétrécie par la droite	Danger
25	Travaux en cours	Danger
26	Signaux lumineux (Feux)	Danger
27	Passage piétons	Danger
28	Attention enfants	Danger
29	Circulation de cyclistes	Danger
30	Attention neige ou verglas	Danger
31	Passage d'animaux sauvages	Danger
32	Fin de toutes interdictions	Fin d'interdiction
33	Direction obligatoire à droite	Obligation
34	Direction obligatoire à gauche	Obligation
35	Direction obligatoire tout droit	Obligation
36	Tout droit ou à droite	Obligation
37	Tout droit ou à gauche	Obligation
38	Contournement obligatoire par la droite	Obligation
39	Contournement obligatoire par la gauche	Obligation
40	Rond-point	Obligation
41	Fin d'interdiction de dépasser	Fin d'interdiction
42	Fin d'interdiction de dépasser (poids lourds)	Fin d'interdiction